

RÉPUBLIQUE DU BÉNIN



MINISTÈRE DE L'ENSEIGNEMENT
SUPÉRIEUR ET
DE LA RECHERCHE SCIENTIFIQUE



UNIVERSITÉ D'ABOMEY-CALAVI (UAC)

*INSTITUT DE FORMATION ET DE RECHERCHE EN
INFORMATIQUE (IFRI)*

MASTER 1 : Big Data

Travaux pratiques n° 4

Clustering IoT par K-Means MapReduce

Modélisation parallèle sur capteurs distribués — 5 serveurs régionaux

Génie Logiciel

Réalisé par :

DOSSOU Persévérance
LOKOSSOU Iréné
AMOUSSOU Gisé
MVOGO Bandolo Samira Anaïs
GOUDALO Brice

Sous la supervision de :

Dr John AOGA

Année académique : 2025-2026

Table des matières

1	Introduction	2
2	Modélisation du problème	2
2.1	Représentation des données	2
2.2	Pourquoi le parallélisme est-il applicable ?	2
2.3	Architecture générale du système	3
3	Le pipeline MapReduce appliqué au K-Means	3
3.1	Phase MAP + COMBINE : calcul local sur chaque serveur	3
3.2	Phase SHUFFLE et REDUCE	3
3.3	Efficacité du Combiner	4
3.4	Initialisation K-Means++	4
4	Implémentation et résultats préliminaires	4
4.1	Organisation des modules	4
4.2	Code du Mapper-Combiner et du Reducer	5
4.3	Exemple concret : 6 capteurs sur 2 serveurs	6
5	Résultats et performances	7
5.1	Phase 1 — Benchmark sur fichiers CSV réels	7
5.2	Scalabilité — montée en charge et projections milliard	7
5.3	Discussion des résultats	8
5.4	Qualité des clusters produits	8
6	Conclusion	9

1 Introduction

Les réseaux de capteurs IoT (*Internet of Things*) génèrent des volumes de données croissants, répartis sur plusieurs sites géographiques. Dans ce contexte, regrouper automatiquement des milliers de capteurs en zones aux comportements similaires constitue un problème central de l'analyse Big Data.

L'algorithme de clustering K-Means est une solution classique à ce problème. Cependant, son exécution séquentielle sur un seul processeur atteint rapidement ses limites lorsque le volume de données augmente. Le paradigme **MapReduce** offre une alternative : en distribuant les calculs sur plusieurs nœuds, il permet de traiter de grands volumes de données tout en conservant la précision de l'algorithme d'origine.

Ce rapport présente l'implémentation et l'évaluation du K-Means MapReduce appliqué à un réseau IoT simulé de cinq serveurs régionaux (Nord, Centre, Sud, Ouest, Est), chacun stockant les mesures de 300 capteurs, soit 1 500 capteurs au total. Les expériences ont été conduites sur une machine à 4 CPU logiques. Le rapport s'organise comme suit : la section 2 modélise le problème et décrit l'architecture parallèle ; la section 3 détaille le pipeline MapReduce ; la section 4 présente l'implémentation ; la section 5 analyse les performances mesurées ; la section 6 conclut.

2 Modélisation du problème

2.1 Représentation des données

Chaque capteur est décrit par un vecteur de quatre mesures physiques collectées en continu. Ces quatre dimensions constituent l'**espace de features** dans lequel l'algorithme K-Means calcule les distances et identifie les clusters.

Feature	Unité	Plage	Signification
temperature	°C	13–38	Température ambiante
humidity	%	30–90	Humidité relative
vibration	m/s ²	0.3–3.0	Vibrations mécaniques
network_traffic	kbps	40–700	Trafic réseau local

2.2 Pourquoi le parallélisme est-il applicable ?

À chaque itération du K-Means, l'opération la plus coûteuse est l'**affectation** de chaque capteur au cluster dont le centroïde est le plus proche. Cette affectation est calculée par la distance euclidienne :

$$\text{cluster}(p) = \arg \min_{k=1}^K \|p - c_k\|_2$$

Le point essentiel est que ce calcul est *totalelement indépendant d'un capteur à l'autre* : le résultat pour le capteur i ne dépend pas du capteur j . Il est donc possible de répartir les capteurs sur plusieurs workers qui effectuent ces calculs simultanément, sans coordination

ni échange de données entre eux. Cette propriété est le fondement de la parallélisation par MapReduce.

2.3 Architecture générale du système

L'architecture retenue place les données au plus près de leur source : chaque serveur régional conserve ses 300 capteurs localement et exécute sa phase de calcul sans transfert préalable des données brutes. Seuls les résultats intermédiaires agrégés transitent vers le nœud central.




Figure 1: Pipeline MapReduce : 5 serveurs en parallèle → Shuffle → Reducer

3 Le pipeline MapReduce appliqué au K-Means

Une itération complète du K-Means MapReduce se déroule en trois phases enchaînées : MAP+COMBINE (exécuté en parallèle sur chaque serveur), SHUFFLE (regroupement des résultats) et REDUCE (calcul des nouveaux centroïdes). Ces phases se répètent jusqu'à convergence.

3.1 Phase MAP + COMBINE : calcul local sur chaque serveur

La phase MAP est exécutée par un **mapper** sur chaque serveur régional. Pour chaque capteur de son lot de données, le mapper calcule la distance euclidienne aux K centroïdes courants et assigne le capteur au cluster le plus proche. Ce travail est effectué sur les données locales, sans communication inter-serveurs.

Le **Combiner** agrège ensuite localement les capteurs du même cluster : au lieu de 300 enregistrements, chaque serveur envoie seulement K sommes partielles (somme des features + compteur). Ceci réduit le trafic réseau d'un facteur $300/K = 100\times$ avec $K = 3$.

3.2 Phase SHUFFLE et REDUCE

Le Shuffle regroupe les partiels par cluster. Le Reducer calcule ensuite le nouveau centroïde de chaque cluster en combinant les sommes partielles :

$$c_k^{\text{new}} = \frac{\sum_w (\text{somme}_w^{(k)})}{\sum_w n_w^{(k)}}$$

Cette opération est **mathématiquement exacte** et produit le même résultat que l'algorithme séquentiel.

3.3 Efficacité du Combiner

Sans Combiner, chaque serveur transmettrait les N enregistrements bruts de ses capteurs, soit $N \times W = 300 \times 5 = 1\,500$ enregistrements au total. Grâce au Combiner, chaque serveur n'envoie que K sommes partielles, soit $K \times W = 3 \times 5 = 15$ valeurs. Le trafic réseau est ainsi réduit d'un facteur $N/K = 100$ à l'échelle de base. Pour le dataset de stress à 50 000 capteurs au total ($\approx 10\,000$ par partition selon le nombre de workers), ce facteur monte à $\approx 3\,333$, ce qui illustre l'importance du Combiner à grande échelle.

3.4 Initialisation K-Means++

La qualité du clustering dépend du choix des centroïdes initiaux. L'implémentation utilise l'heuristique **K-Means++** : le premier centroïde est choisi aléatoirement, puis chaque centroïde suivant est sélectionné avec une probabilité proportionnelle au carré de sa distance au centroïde existant le plus proche. Cette stratégie réduit le risque de convergence vers des minima locaux et améliore la qualité finale des clusters.

4 Implémentation et résultats préliminaires

4.1 Organisation des modules

Le pipeline est implémenté en Python avec une séparation claire des responsabilités.

Module	Responsabilités
generate_data.py	Génération des données IoT simulées : 5 serveurs régionaux, 300 capteurs/serveur, 3 profils de comportement + dataset stress 50k
utils.py	Fonctions utilitaires partagées : distance euclidienne, normalisation z-score, SSE, K-Means++, chargement CSV
kmeans_mr_job.py	Cœur MapReduce : mapper-combiner, shuffle, reducer, orchestrateur d'itération, <code>multiprocessing.Pool</code>
kmeans_mapreduce.py	Boucle itérative K-Means, critère de convergence, mode chunk et mode multi-serveurs
kmeans_classic.py	K-Means séquentiel de référence, timeout configurable
benchmark.py	Benchmark comparatif en 3 phases (fichiers CSV, montée en charge, projections milliard) ; timeout 20 s
simulation_comparison.py	Montée en charge 10k–1M (dashboard) ou 1k–2M (complet) ; simulation réseau IoT 1 Mbps ; timeout 15 s en mode complet

Chaque module a des dépendances minimales et peut être testé indépendamment. L'architecture favorise la maintenabilité et l'extension future.

4.2 Code du Mapper-Combiner et du Reducer

Le code implémente directement les phases MAP, COMBINE et REDUCE décrites en section 3. Le Mapper-Combiner s'exécute en parallèle via `multiprocessing.Pool` sur les W serveurs ; le Reducer s'exécute ensuite une seule fois pour produire les nouveaux centroïdes.

Détails d'implémentation :

- Le mapper parcourt chaque capteur du chunk, calcule sa distance à chaque centroïde via la distance euclidienne, et l'assigne au cluster le plus proche.
- Le combiner agrège les capteurs du même cluster en une seule entrée : somme des vecteurs de features et compteur d'éléments.
- Le reducer reçoit toutes les sommes partielles d'un cluster et les combine pour calculer le centroïde final.
- La convergence est vérifiée par la norme L2 entre centroïdes successifs : $\|c_k^{\text{old}} - c_k^{\text{new}}\|_2 < 10^{-4}$.

```

1 def mapper_combiner(args):    # called via Pool.map (single tuple argument)
2     chunk_lines, centroids = args
3     partial = {}
4     for line in chunk_lines:
5         line = line.strip()
6         if not line or line.startswith("sensor_id"):
```

```

7         continue
8     parts = line.split(",")
9     try:
10         point = [float(parts[i]) for i in FEATURE_INDICES]
11     except (ValueError, IndexError):
12         continue
13     distances = [euclidean(point, c) for c in centroids]
14     cluster_id = distances.index(min(distances))
15     if cluster_id not in partial:
16         partial[cluster_id] = ([0.0]*len(point), 0)
17     s, cnt = partial[cluster_id]
18     partial[cluster_id] = ([s[d]+point[d] for d in range(len(point))], cnt+1)
19 return partial
20
21 def reducer(cluster_id, values):
22     total_sum, total_count = None, 0
23     for partial_sum, count in values:
24         total_sum = (list(partial_sum) if total_sum is None
25                      else [a+b for a,b in zip(total_sum, partial_sum)])
26         total_count += count
27     new_centroid = ([s/total_count for s in total_sum] if total_count > 0
28                    else total_sum or [0.0]*4)
29     return cluster_id, new_centroid, total_count

```

Listing 1: Mapper-Combiner et Reducer (kmeans_mr_job.py)

L'orchestrateur commence par soumettre les chunks aux workers via `Pool.map`. Il collecte ensuite les résultats partiels et les regroupe par identifiant de cluster (phase Shuffle). Enfin, il appelle le Reducer pour calculer les nouveaux centroïdes. À chaque itération, la convergence est contrôlée par la condition $\|c_k^{\text{old}} - c_k^{\text{new}}\|_2 < 10^{-4}$, ce qui garantit la stabilité des résultats tout en limitant le nombre d'itérations nécessaires.

4.3 Exemple concret : 6 capteurs sur 2 serveurs

On considère 6 capteurs ($K=2$, features : température T et humidité H) sur 2 serveurs. Centroïdes K-Means++ : $C_0=[34, 78]$ (rural/chaud), $C_1=[22, 44]$ (urbain).

Itération 1 — MAP : chaque serveur calcule $d=\sqrt{\Delta T^2 + \Delta H^2}$ et affecte au plus proche.

Serv.	Capteur	$d(\cdot, C_0)$	$d(\cdot, C_1)$	Aff.
A	$S_1 = [34, 78]$	0.00	36.06	C_0
A	$S_2 = [36, 82]$	4.47	40.50	C_0
A	$S_3 = [33, 75]$	3.16	32.89	C_0
B	$S_4 = [21, 42]$	38.28	2.24	C_1
B	$S_5 = [23, 48]$	31.95	4.12	C_1
B	$S_6 = [22, 44]$	36.06	0.00	C_1

COMBINE : Srv. A émet $\{C_0 : ([34+36+33, 78+82+75], 3)\} = \{C_0 : ([103, 235], 3)\}$; Srv. B émet $\{C_1 : ([21+23+22, 42+48+44], 3)\} = \{C_1 : ([66, 134], 3)\}$. **2 émissions réseau** au lieu de 6 enregistrements bruts.

SHUFFLE : le Reducer reçoit $C_0 \leftarrow ([103, 235], 3)$ depuis A et $C_1 \leftarrow ([66, 134], 3)$ depuis B.

REDUCE :

$$C_0^{\text{new}} = \frac{[103,235]}{3} = [34,33, 78,33] \quad C_1^{\text{new}} = \frac{[66,134]}{3} = [22,00, 44,67]$$

$\|C_0^{\text{new}} - C_0\| \approx 0,47 > 10^{-4} \rightarrow$ non convergé ; itération 2 nécessaire.

Itération 2 : les affectations sont inchangées $\rightarrow$ sommes partielles identiques $\rightarrow \| \Delta C \| = 0 < 10^{-4}$: **convergé en 2 itérations**.

Résultat final : $C_0 = \{S_1, S_2, S_3\}$ (34,33 °C, 78,33%, rural) ; $C_1 = \{S_4, S_5, S_6\}$ (22,00 °C, 44,67%, urbain). Résultat **identique à l'algorithme classique** — l'agrégation par sommes partielles est mathématiquement exacte. Gain réseau : $N/K=3$ ici, $100\times$ sur les données réelles.

5 Résultats et performances

Cette section présente une évaluation comparative entre l'approche classique et MapReduce selon trois axes : le temps d'exécution brut, la scalabilité face à la montée en charge, et la qualité des clusters produits.

5.1 Phase 1 — Benchmark sur fichiers CSV réels

Les mesures ont été réalisées sur une machine à 4 CPU logiques, avec $K = 3$ clusters, un maximum de 10 itérations et un timeout de 20 s (`benchmark.py`).

Dataset	Points	Classique (s)	MapReduce (s)	Ratio
Normal	1 500	0.072	0.125	overhead 1.74× (pool de processus)
Stress test	50 000	2.417	1.002	2.41× — plus rapide
Multi-serveurs	1 500	0.071	0.141	overhead 1.99× (normal à ce volume)

Observations : Sur le petit dataset de 1 500 capteurs, le surcoût lié à la création du pool de processus est mesurable mais reste faible (environ 50 ms). En revanche, sur 50 000 capteurs, le parallélisme devient clairement avantageux : MapReduce atteint un speedup de $2.41\times$ ($2.417\text{s}/1.002\text{s}$).

5.2 Scalabilité — montée en charge et projections milliard

Ces mesures portent sur des données synthétiques avec un timeout de 20 s. Les colonnes *Classique (calcul)* et *MapReduce (calcul)* indiquent le **temps de calcul pur** pour chaque approche. La colonne *Gain total réseau* compare les temps **totaux** en y ajoutant le coût de transfert réseau : pour l'approche classique, toutes les données brutes doivent transiter sur un lien IoT à 1 Mbps ; pour MapReduce, seules 15 sommes partielles sont envoyées sur

un LAN Gigabit. Pour les lignes extrapolées (10M à 1G capteurs), la colonne *Classique* affiche directement le temps total (calcul + réseau).

Capteurs	Classique (calcul)	MapReduce (calcul)	Gain total réseau
100 000	3.978 s	2.427 s	29.6 s vs 2.4 s → 12.2×
500 000	TIMEOUT	12.657 s	>2 min vs 12.7 s → 11.7×
1 000 000	TIMEOUT	31.360 s	≈4.6 min vs 31.4 s → 8.8×
<i>Extrapolation $O(n)$ — classique depuis 100k cap., MR depuis 1M cap. (réseau IoT 1 Mbps)</i>			
10 000 000	≈49 min (total)	≈5 min	9.4×
100 000 000	≈8.2 h (total)	≈52 min	9.4×
1 000 000 000	≈ 3.4 jours	≈8.7 h	9.4×

Le seuil critique se situe à **500 000 capteurs**. En dessous de ce seuil, l'approche classique reste utilisable ; au-delà, elle dépasse le timeout de 20 s alors que MapReduce converge en 12.657 s. À l'échelle du milliard, l'écart devient radical : rien que le transfert des données brutes (32 Go à 1 Mbps) mobilise le réseau pendant environ 3 jours, avant même que le calcul puisse commencer. MapReduce, lui, livre le résultat en ≈8,7 h, soit un gain de 9,4×

5.3 Discussion des résultats

Overhead vs bénéfice : À faible volume (1 500 capteurs), la création du pool coûte ≈50 ms et génère un overhead. Dès 50 000 capteurs cet overhead est amorti (2.41×) ; au-delà de 500 000, l'approche classique dépasse le timeout et MapReduce devient la seule option.

Impact réseau : En contexte IoT réel à 1 Mbps, dès 100 000 capteurs le transfert brut mobilise 25,6 s tandis que MapReduce n'envoie que 15 sommes partielles (<1 ms) : gain total 12.2×. Ce déséquilibre réseau devient dominant au milliard.

5.4 Qualité des clusters produits

Cette section vérifie que la parallélisation ne dégrade pas la qualité du clustering. Nous comparons pour cela les centroïdes et la SSE obtenus par les deux approches sur le dataset de référence de 1 500 capteurs avec $K = 3$ clusters.

Cluster	Centroïde	Taille	Profil identifié
C_0	[27.6°C, 59.3%, 1.08 m/s ² , 260 kbps]	524	Suburbain : conditions inter-médiaires
C_1	[34.3°C, 78.3%, 0.53 m/s ² , 124 kbps]	525	Zone rurale/forestière : chaude, humide
C_2	[22.2°C, 45.2%, 2.49 m/s ² , 512 kbps]	451	Urbain industriel : vibration, trafic élevés

Les deux algorithmes produisent exactement la même somme des erreurs quadratiques : $SSE_{\text{classique}} = SSE_{\text{MapReduce}} = 3\,550\,130.6$. Les trois clusters identifiés correspondent à des profils IoT distincts et cohérents. Ces résultats confirment que la parallélisation par MapReduce ne compromet en rien la précision du clustering.

6 Conclusion

Ce travail a mis en œuvre et évalué le paradigme MapReduce pour le clustering K-Means sur un réseau de capteurs IoT distribués. Cinq enseignements principaux se dégagent.

1. **Exactitude mathématique** : MapReduce produit exactement le même résultat que l'algorithme classique : la SSE est identique (3 550 130.6), car l'agrégation par sommes partielles est une transformation mathématiquement exacte.
2. **Seuil de rentabilité** : MapReduce devient avantageux dès **50 000 capteurs** en calcul pur ($2.41\times$) et plus tôt encore en scénario IoT réel — à 100 000 capteurs, le gain total atteint déjà $12.2\times$.
3. **Efficacité réseau du Combiner** : En réduisant N enregistrements à K sommes partielles, le Combiner divise le trafic d'un facteur N/K , soit $\times 100$ à l'échelle de base et $\times 3\,333$ à 50 000 capteurs au total.
4. **Seuil critique à 500 000 capteurs** : Au-delà de ce seuil, l'algorithme classique dépasse le timeout de 20 s alors que MapReduce termine dans tous les cas testés jusqu'à 1 000 000 capteurs (31.360 s).
5. **Projection à l'échelle milliard** : À 1 milliard de capteurs, le classique nécessite $\approx 3,4$ jours contre $\approx 8,7$ h pour MapReduce ($9,4\times$) : MapReduce *termine* pendant que le classique *collecte encore les données*.

MapReduce pour K-Means offre ainsi exactitude, scalabilité et efficacité réseau, avec un avantage qui s'amplifie à mesure que le volume de données croît.