

TP4 : Projet avec MapReduce

@John Aoga (johnaoga@gmail.com/0197999277) — IFRI/Master 1/GL : Big data

Délai : 07 juin

Objectif :

L'objectif de ce projet est d'évaluer votre capacité à:

- lire et comprendre de la documentation technique
- pouvoir expliquer clairement et précisément un algorithme (notamment celui de map-reduce)
- pouvoir l'implémenter
- ~~pouvoir présenter l'utilisation de modèles complexes, derrière des interfaces simples~~
- modéliser un problème sous la forme ou map-reduce pourrait lui être appliqué



Attention : Il s'agit pas juste d'un TP de développement donc, il sera évalué ici votre capacité à représenter un problème sous la forme de map-reduce, l'implémentation de map-reduce et les résultats obtenus

Livrables :

- Code Implémenté - 30% - GitHub (johnaoga@gmail.com)
- Rapport (maximum 10 pages) - 50%
- Video (maximum 5min expliquant l'exécution et les résultats de votre travail) - 20%

Répartition :

Groupes	Problèmes
1 -	Implémenter l'algorithme de facteur latent (SVD) pour traiter de grands ensembles de données d'une plateforme musicales dont les données sont distribuées sur plusieurs serveur, et proposer des recommandations personnalisés pour des utilisateurs données.
2-	Implémenter l'algorithme de kmeans pour regrouper des capteurs IoT répartis géographiquement et générant continuellement des données telles que la température, l'humidité, la vibration, le trafic réseau. Ces données sont stockées localement sur différents serveurs régionaux.
3-	Implémenter un algorithme de FIM de façon distribuée en utilisant map reduce (imaginer qu'au lieu d'avoir une seule dataset, il y a plusieurs datasets, comment effectuer l'opération de sorte qu'on peut retrouver les patterns fréquents à la fin)
4-	Implémenter un algorithme d'éléments similaire de façon distribuée en utilisant map reduce pour identifier des documents plagiés (imaginer qu'il y a des documents répartis sur plusieurs serveurs et qu'on vous demande lesquels ont plagiés par rapport au document fourni) - scénari1: les documents tiennent sur un serveur; scénari2: les documents tiennent sur plusieurs serveurs
5-	Utilisez MapReduce pour analyser des structures de graphes des réseaux sociaux pour rechercher des chemins (les plus courts) entre les nœuds. (Friend recommendation system)
6-	Utilisez MapReduce pour analyser des structures de graphes des réseaux sociaux pour rechercher des chemins (les plus courts) entre les nœuds. (Information Spread Analysis)
7-	Utilisez MapReduce pour analyser des structures de graphes de web, incluant le calcul du PageRank des pages web (imaginer la réalisation d'un moteur de recherche efficace en utilisant MapReduce et PageRank)

Consignes

1. Implémenter l'algorithme de map-reduce pour résoudre le problème à vous assigner

2. Simuler un cas ou vous essayer de lancer l'algorithme classique sur votre ordinateur (mettre un timeout pour ne pas y perdre la journée) et comparer son efficacité avec la version distribuée implémentée.
3. Ecrire le rapport
 - a. Décrire comment avez-vous modélisé votre problème dans le sens d'exécution parallèle
 - b. expliquer ce que représentent vos mappers et reducers
 - c. expliquer brièvement le code
 - d. donner exemple de son exécution sur un exemple simple et expliquer le résultat obtenu
 - e. montrer la comparaison single execution and map-reduce execution